2026 AI·SW중심대학 디지털 경진대회 : AI부문

7.1 ~ 7.15

박진영 김서연 임우진 임우영

가천대학교 AI·소프트웨어학부
Gachon University

Intelligent Networking &
Computing Laboratory

X

- id : 샘플 고유 식별자 (예: sess_sim_20260522_028750-step_02)

- session_meta : 세션·작업공간 메타정보
  - 요금제, 선호언어, 잔여토큰, 현재 턴 번호, 세션 경과 시간, 작업공간 상태, 코드베이스 언어 비율, 전체 코드 라인 수, 미커밋 변경 존재 여부, 열려있는 파일 경로 목록, 마지막 CI 상태 (passed / failed / none)

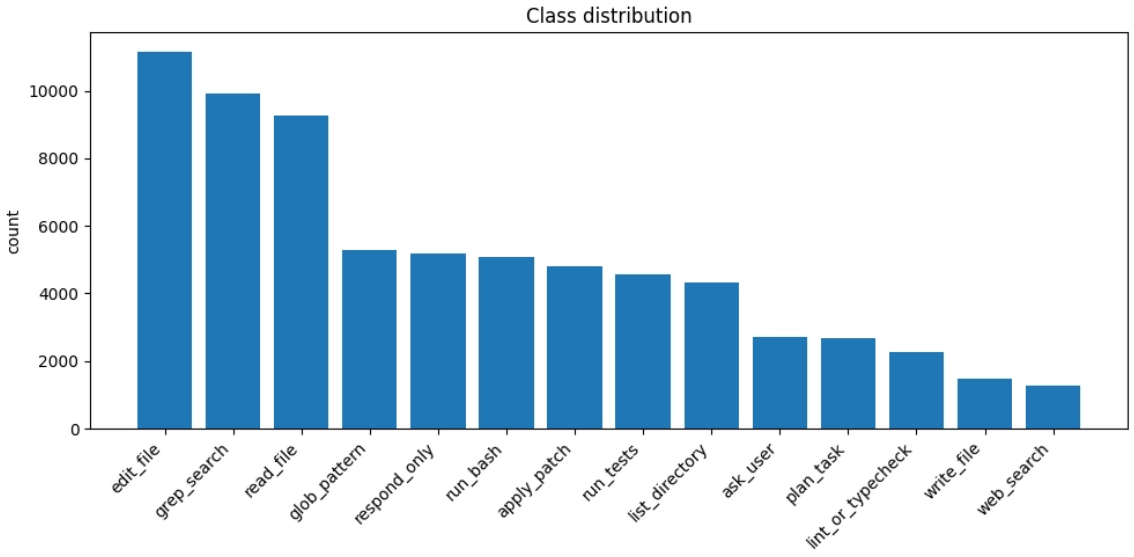
- history : 이전까지의 대화·행동 기록 (시간순, 0~12개, user → assistant_action 교대)

- current_prompt : 현재(가장 최근) 사용자 발화 — 이 시점에서의 다음 행동이 예측 대상

© INC Lab. All right reserved.

Target (y)

- **탐색 / 조회 : 파일이나 디렉토리를 읽고 찾기만 함. 가장 수동적이고 안전한 단계**
  - read_file : 파일 내용을 읽음
  - grep_search : 파일 안에서 특정 문자열 / 패턴을 검색함
  - glob_pattern : 파일 이름이나 경로 패턴으로 파일을 찾음
  - list_directory : 폴더 안의 파일 / 하위 폴더 목록을 확인함
- **판단 / 확장 : 계획을 세우거나 사용자에게 묻거나 외부 정보를 가져옴**
  - plan_task : 바로 실행하지 않고 작업 계획을 세움
  - ask_user : 사용자에게 추가 질문을 함
  - web_search : 웹에서 정보를 검색함
- **실행 / 검증 : 코드를 실행하거나 테스트, 린트, 타입체크로 확인함**
  - run_bash : 터미널에서 명령어 실행
  - run_tests : 테스트 실행
  - lint_or_typecheck : 린트나 타입 검사 실행
- **수정 / 생성 : 실제 파일 내용을 바꾸거나 새로 작성함**
  - write_file : 새 파일을 만들거나 파일 내용을 전체적으로 작성
  - edit_file : 기존 파일의 일부를 수정
  - apply_patch : 코드 변경사항을 패치 / diff 형태로 적용
- **repond_only : 즉시 응답**



© INC Lab. All right reserved.

초반진행 (~0.73)

- 대회 전 공유했던 실제 ai 에이전트의 작동을 소개한 블로그를 레퍼런스로 참고하여 3-Tier Routing cascading 구조를 설계하고자 함




```
Request → [Tier 1: Condition Router] → confidence ≥ 0.8? → Route
                                    ↓ no
          [Tier 2: Semantic Matcher] → confidence ≥ 0.8? → Route
                                    ↓ no
                [Tier 3: LLM Router] → Route
```

- **Tier 1 : 선형모델 기반 Condition Router을 통해 빠르게 routing**
- **Tier 2 : tier1에서 신뢰도가 낮은 샘플에 대해서 semantic matcher (트랜스포머 기반) 실행**
- **Tier 3 : 이 대회에서는 LLM 앞단을 설계**

© INC Lab. All right reserved.

초반진행 (~0.73)

클래스별 컨피던스 계측 전체 정리 (005 OOF, 70,000건)

전체 표

클래스	예측 수	기본 정밀도	t@95	keep@95 (비율)	t@90	keep@90 (비율)
respond_only	5,176	1.000	0.051	5,176 (100%)	0.051	5,176 (100%)
write_file	1,481	0.991	0.022	1,481 (100%)	0.022	1,481 (100%)
edit_file	11,108	0.875	0.508	7,588 (68%)	0.130	10,313 (93%)
apply_patch	5,211	0.700	0.898	524 (10%)	0.708	1,606 (31%)
run_bash	5,028	0.733	0.975	21 (0.4%)	0.885	501 (10%)
lint_or_typecheck	2,175	0.490	0.948	42 (1.9%)	0.886	92 (4.2%)
run_tests	4,781	0.643	0.963	9 (0.2%)	0.959	13 (0.3%)
grep_search	9,305	0.584	0.952	2 (0%)	0.952	2 (0%)
read_file	8,535	0.505	0.934	2 (0%)	0.934	2 (0%)
glob_pattern	4,850	0.592	0.979	1 (0%)	0.979	1 (0%)
list_directory	5,786	0.354	불가	0	불가	0
plan_task	2,665	0.556	0.984	3 (0.1%)	0.964	10 (0.4%)
ask_user	2,793	0.513	0.969	2 (0%)	0.969	2 (0%)
web_search	1,106	0.424	0.937	6 (0.5%)	0.937	6 (0.5%)

실험	CV Macro-F1	cov@95 / cov@90	변경점
001_tfidf_baseline	0.4363	10.0% / 11.0%	current_prompt TF-IDF + LogReg
002_+structure	0.5466	14.7% / 19.9%	+ 구조 피처 (직전 액션, CI 상태, 확장자 언급 등)
003_+lexicon	0.5453	15.4% / 20.6%	+ lexicon 14종 – CV 하락, 되돌림
004_calibrated_svc	0.5280	13.7% / 21.2%	SVC 교체 – macro-F1 하락 (보정 품질만 우세)
006_history_tfidf	0.5921	12.6% / 21.8%	+ history 별도 TF-IDF (최근 4턴)
007_history_result	0.6076	13.2% / 23.5%	history에 result_summary 포함 (+0.0155로 승리)
005_lgbm_blend	**0.6391**	**18.0% / 29.2%**	007 + LGBM 확률 평균 0.5:0.5 – 현재 최고

Tier-1

- Tier-1에서 **선형모델을** 이용하여
- 20~30%를 정확도 95 이상으로 빠르게 **early exit**

- **앞에서 시간을 확보해서 tier-2에서 최대한 많은 자원을 쓰자**

***t@95 = 그 클래스에서 "정밀도 95% 이상"을 만족시키는 최소 margin threshold**

***Margin threshold = top1확률 – top2확률**

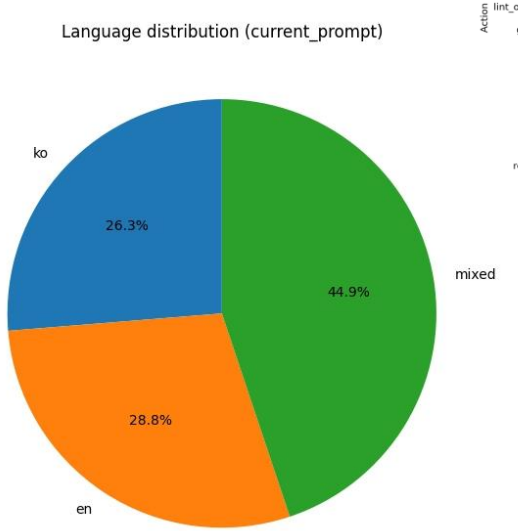
© INC Lab. All right reserved.

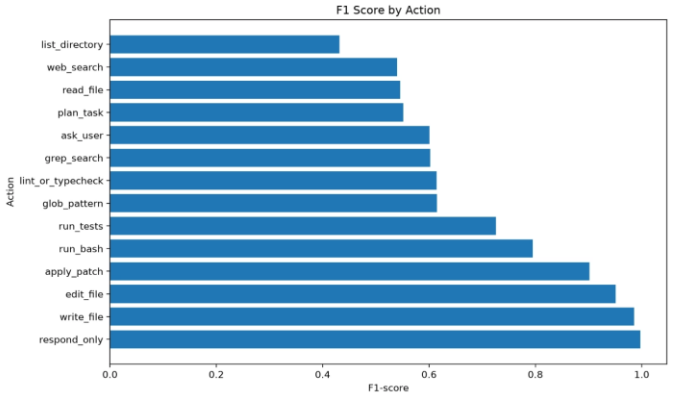
초반진행 (~0.73)

Tier-2

Baseline 모델을 **Klue/RoBERTa-small**을 사용
다양한 입력구조를 활용하여 macro-f1 점수 변화를 체크

Klue/RoBERTa : 샘플에 한/영이 섞여있어 1차적으로 채택함





순위	Action	Precision	Recall	F1-score	Support
1	respond_only	99.73%	100.00%	99.87%	747
2	write_file	98.09%	99.03%	98.56%	207
3	edit_file	94.69%	96.23%	95.45%	1,722
4	apply_patch	91.89%	89.39%	90.62%	773
5	run_bash	81.59%	77.34%	79.41%	728
6	run_tests	70.73%	75.70%	73.13%	683
7	ask_user	66.84%	62.86%	64.79%	420
8	plan_task	64.63%	63.82%	64.22%	398
9	lint_or_typecheck	64.01%	61.64%	62.80%	378
10	glob_pattern	68.53%	56.34%	61.84%	804
11	grep_search	65.48%	56.76%	60.81%	1,517
12	web_search	55.88%	61.01%	58.33%	218
13	read_file	52.13%	60.39%	55.95%	1,401
14	list_directory	41.87%	49.56%	45.39%	686

V2.5 baseline (macroF1 = 0.71) : 초반 베이스라인으로 채택한 모델

Target에 영향을 주는 feature를 뽑아서 앞단에 배치 (최대 512 토큰)
[입력구조]

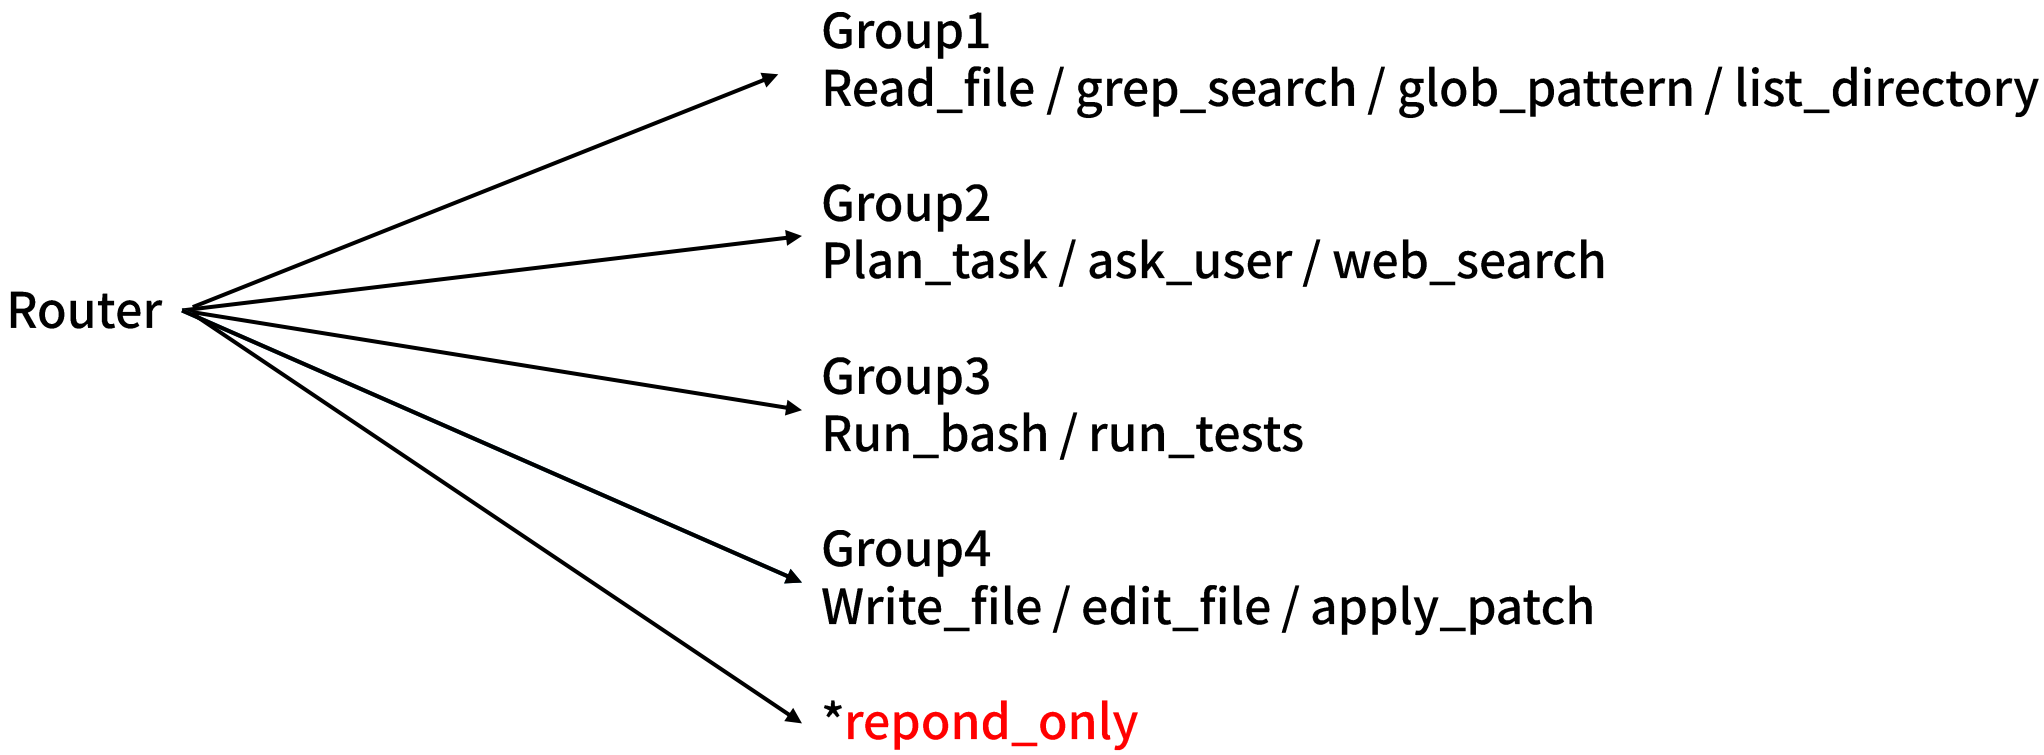
1. 현재발화
2. 직전발화
3. 직전 action
4. 직전 2 pair 상세
5. 나머지 history 요약
6. 나머지 meta data

V2.5 baseline이 가장 안정적이다라고 판단하여 이를 토대로 다양한 실험 진행 (약 4~5일)
➔ 오답 샘플을 반영한 입력구조 변화
➔ 백본 모델 교체 / 상위 모델 실험 (h100 지원 요청)
모델을 교체하거나 파라미터를 키워도 성능이 오히려 하락

© INC Lab. All right reserved.

중반 진행 (~0.76)

- 타겟들이 크게 4그룹을 나뉜다는 사실을 파악 (오답들이 그룹에 따라 움직임)
- 그룹타겟팅시 99% 이상의 정확도를 보임 → 라우팅 설계가 가능하다고 생각함
  - Repond_only는 초반진행에서 거의 100% 맞췄기 때문에 early exit 할 수 있도록 설계

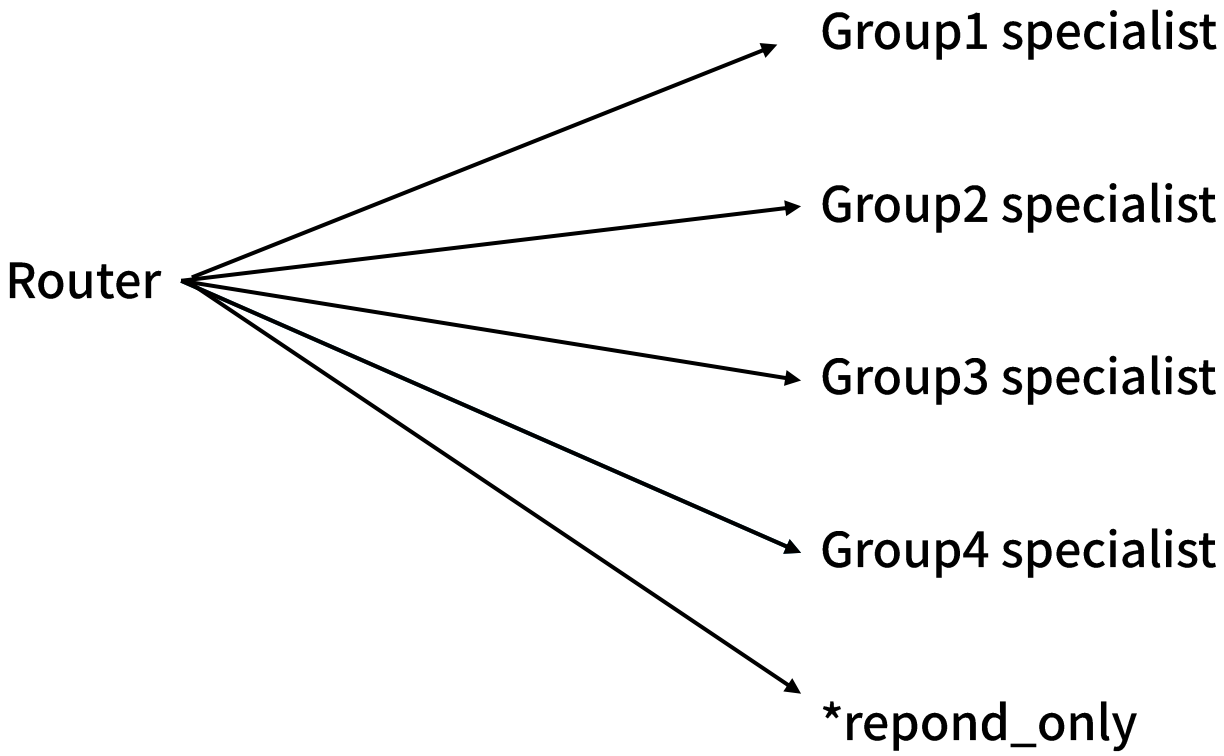


© INC Lab. All right reserved.

중반 진행 (~0.76)

- Router : 초반진행에 사용되었던 Tier 1 재사용
- 한명은 계속 언어모델을 사용하여 14target 예측
- F1이 압도적으로 낮았던 group1 specialist 를 2명에서 담당 -> 다양한 시도
- Group2 / group3 / group4를 각 그룹에 맞는 feature를 구성하여 선형모델 설계

  -> 점수 크게 상승



© INC Lab. All right reserved.

중반 진행 (~0.76)

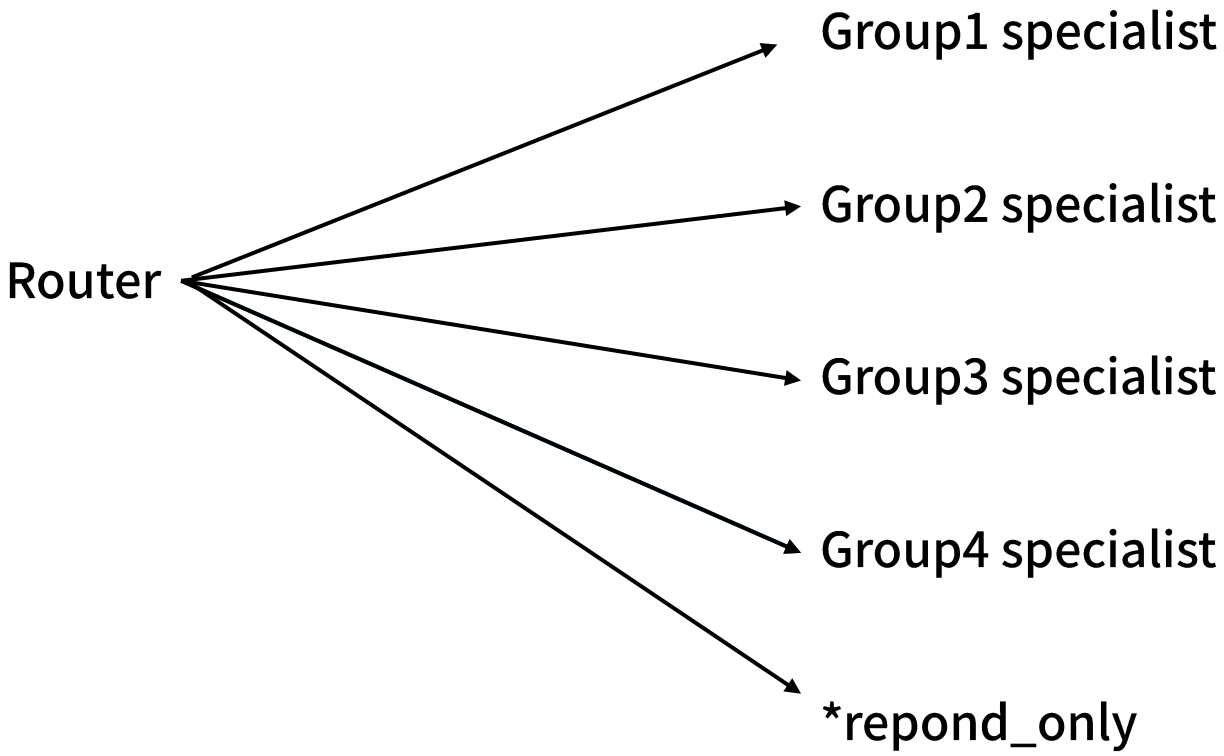
Action	F1
glob_pattern	61.84
grep_search	60.81
read_file	55.95
list_directory	45.39

- Router : 초반진행에 사용되었던 Tier 1 재사용
- 한명은 계속 언어모델을 사용하여 14target 예측
- F1이 압도적으로 낮았던 group1 specialist 를 2명에서 담당 -> 다양한 시도
- 한명은 Group2 / group3 / group4를 각 그룹에 맞는 feature를 구성하여 선형모델 설계

  -> 점수 크게 상승

Action	F1
run_bash	79.41 → 0.8364
run_tests	73.13 → 0.8419
lint_or_typecheck	62.80 → 0.7014

Action	F1
ask_user	64.79 → 66.6
pan_task	64.22 → 70.1
web_search	58.33 → 77



© INC Lab. All right reserved.

중반 진행 (~0.76)

- 한명은 계속 언어모델을 사용하여 14target 예측 실험
- 해당 모델을 group4 expert로 채택

*Group4는 자연어가 타겟 결정에 기여하는바가 큼

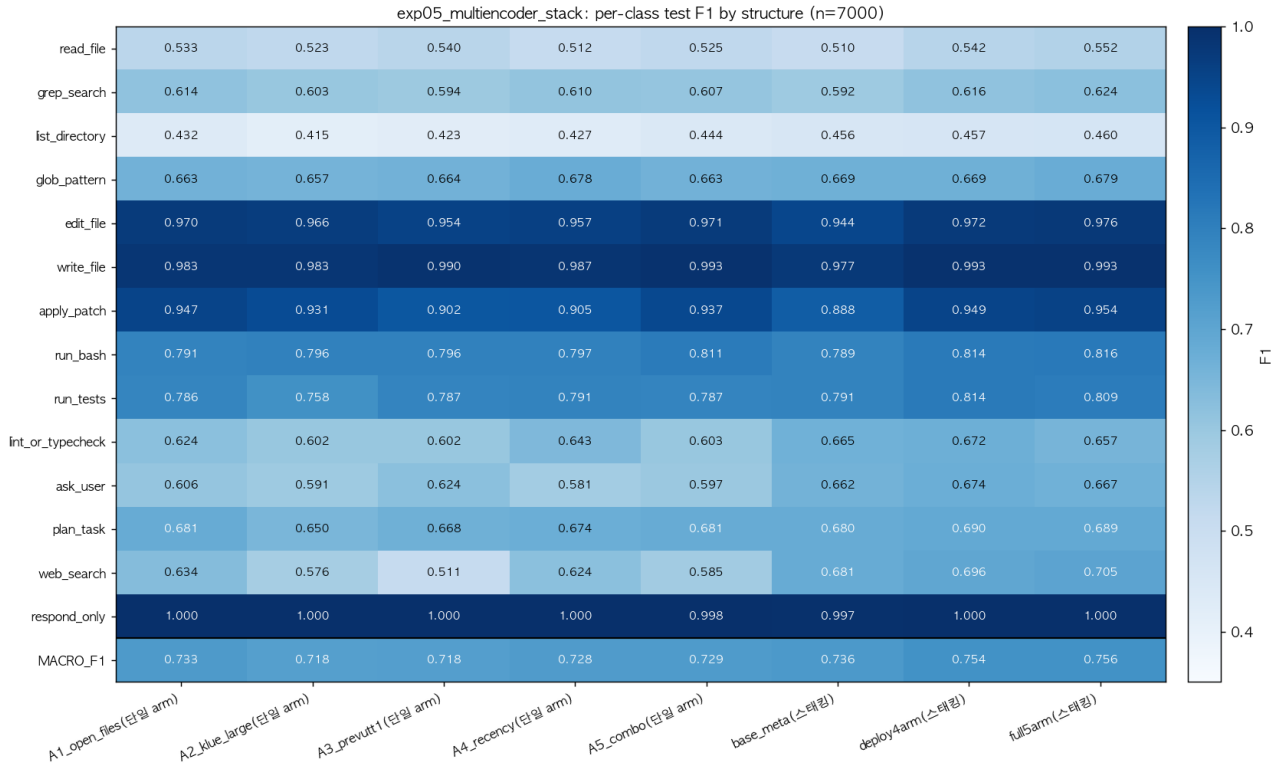
<ctx>
<turn_i>
<ci_status>
<git_status>
<open> 파일경로1 파일경로2 ...
또는 <open_none>

<hist>

[최근 사용자 발화 1개]

<ago_N> <act_ACTION> key=value ... → result_summary
<ago_N> <act_ACTION> key=value ... → result_summary
...

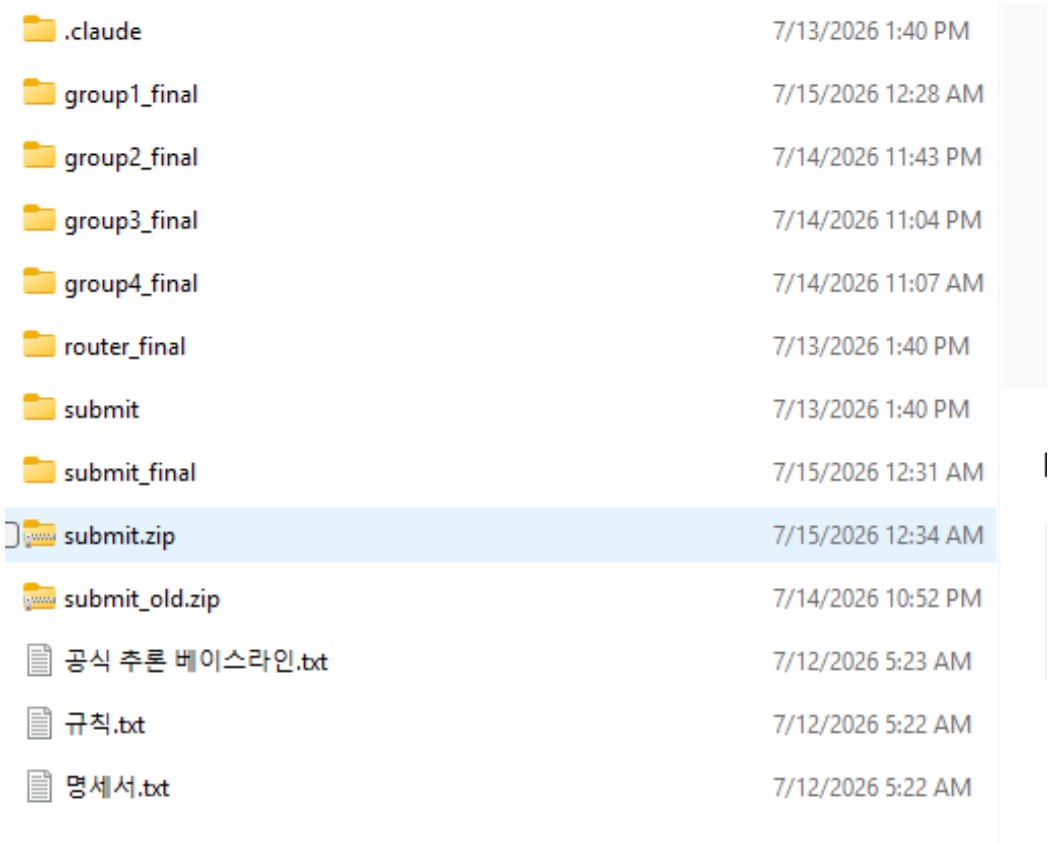
<now>
현재 사용자 프롬프트



© INC Lab. All right reserved.

중반 진행 (~0.76)

- 각 그룹별 모델을 갈아끼우기만 할 수 있도록 제출 형태 고정
- 각 그룹 폴더에 추론코드 / 모델파일 / 전처리코드를 넣으면 claude가 제출파일 생성



© INC Lab. All right reserved.

후반 진행 (~0.78)

- 각 그룹별 모델을 더 끌어올리기 위해 오답샘플 분석과 다양한 시도 진행
- 대부분의 정답률 손실은 시뮬레이션 데이터의 노이즈로부터 발생

Bert의 임베딩값을 선형모델의 feature로 (group1)

타겟의 오답을 분석한 action card와 샘플의 임베딩 유사도 분석

각 그룹별 헷갈리는 타겟들만 추가 라우팅

선형모델 + 언어모델 + 둘중 어느 모델을 따를지 결정하는 판정모델 (group2)

헷갈리는 타겟들만 추가학습

타 그룹까지 모두 학습한 large 모델에 해당 그룹을 추가학습시킨 후 student 모델에 증류 (group2)

모든 그룹을 관통하는 구조는 없었음 -> 각 그룹별 CV 최고성능을 제출

© INC Lab. All right reserved.

후반 진행 (~0.78)

- 각 그룹별 마지막 제출 모델
- Group1 : 선형모델 앙상블
- Group2 : large모델로 전체데이터 학습 후 그룹데이터 추가학습 -> student 모델에 증류 -> 선형모델과 합쳐서 최종 예측 target 생성
- Group3 : group2와 유사
- Group4 : 입력구조 개선 Bert 모델
- Router(+ repond_only) : 발화 위주 선형모델 앙상블

© INC Lab. All right reserved.

아쉬운점

- 초반진행에 시간낭비 -> 상위권 팀들에 비해 뒤늦게 78점대에 도달하여 후반 오답분석 시간이 부족
- 팀원간 협업 및 소통의 어려움
- 전체 학습을 방해하는 큰 요인인 노이즈 처리에 대한 고민이 부족했던 것 같음
- 대회 후반 CV 점수 짜내기에 급급해 체계적인 오답분석/실험설계가 부족했던 것 같아 아쉬움

© INC Lab. All right reserved.

Thank you.